



Junio 2020 | Charlas online

¿Cuándo es posible delegar decisiones a un algoritmo?

Por: Wehrli Pérez Caicer
Sociedad Ecuatoriana de Estadística

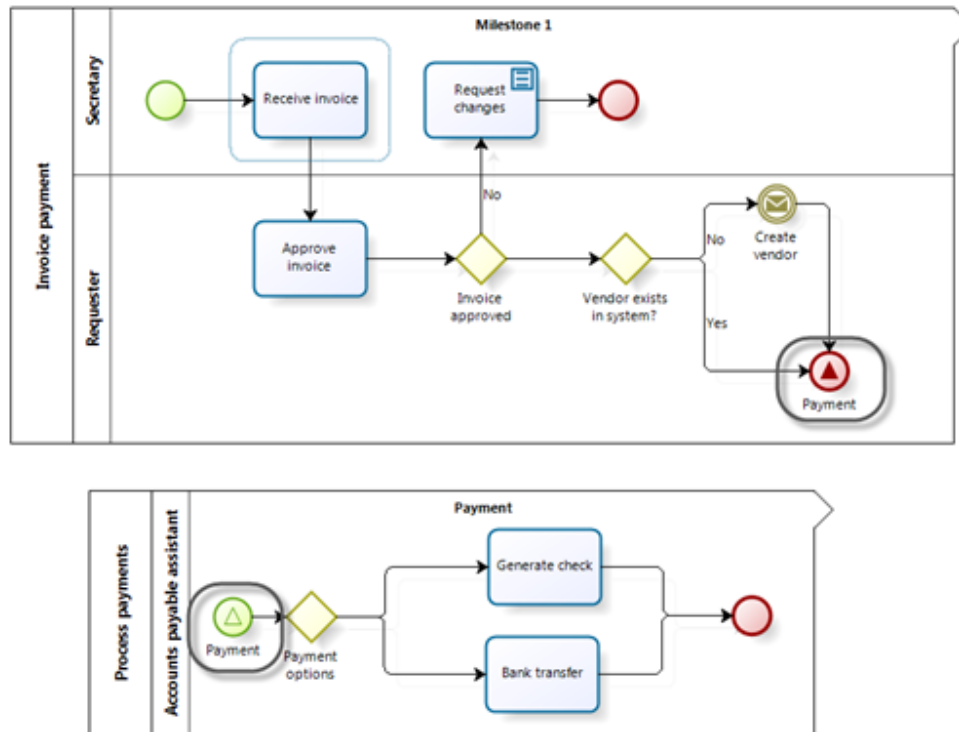


En pruebas de hipótesis, el investigador selecciona cuál es el nivel de significancia (Error tipo I) con el que desea trabajar..

Conclusión basada en análisis de la muestra	Realidad de la población	
	H0 VERDADERA	H1 VERDADERA
	H0 NO ES RECHAZADA	H0 ES RECHAZADA
	Conclusión correcta	Error Tipo II (beta) Falso negativo
	Error Tipo I (alpha) Falso-positivo	Conclusión correcta

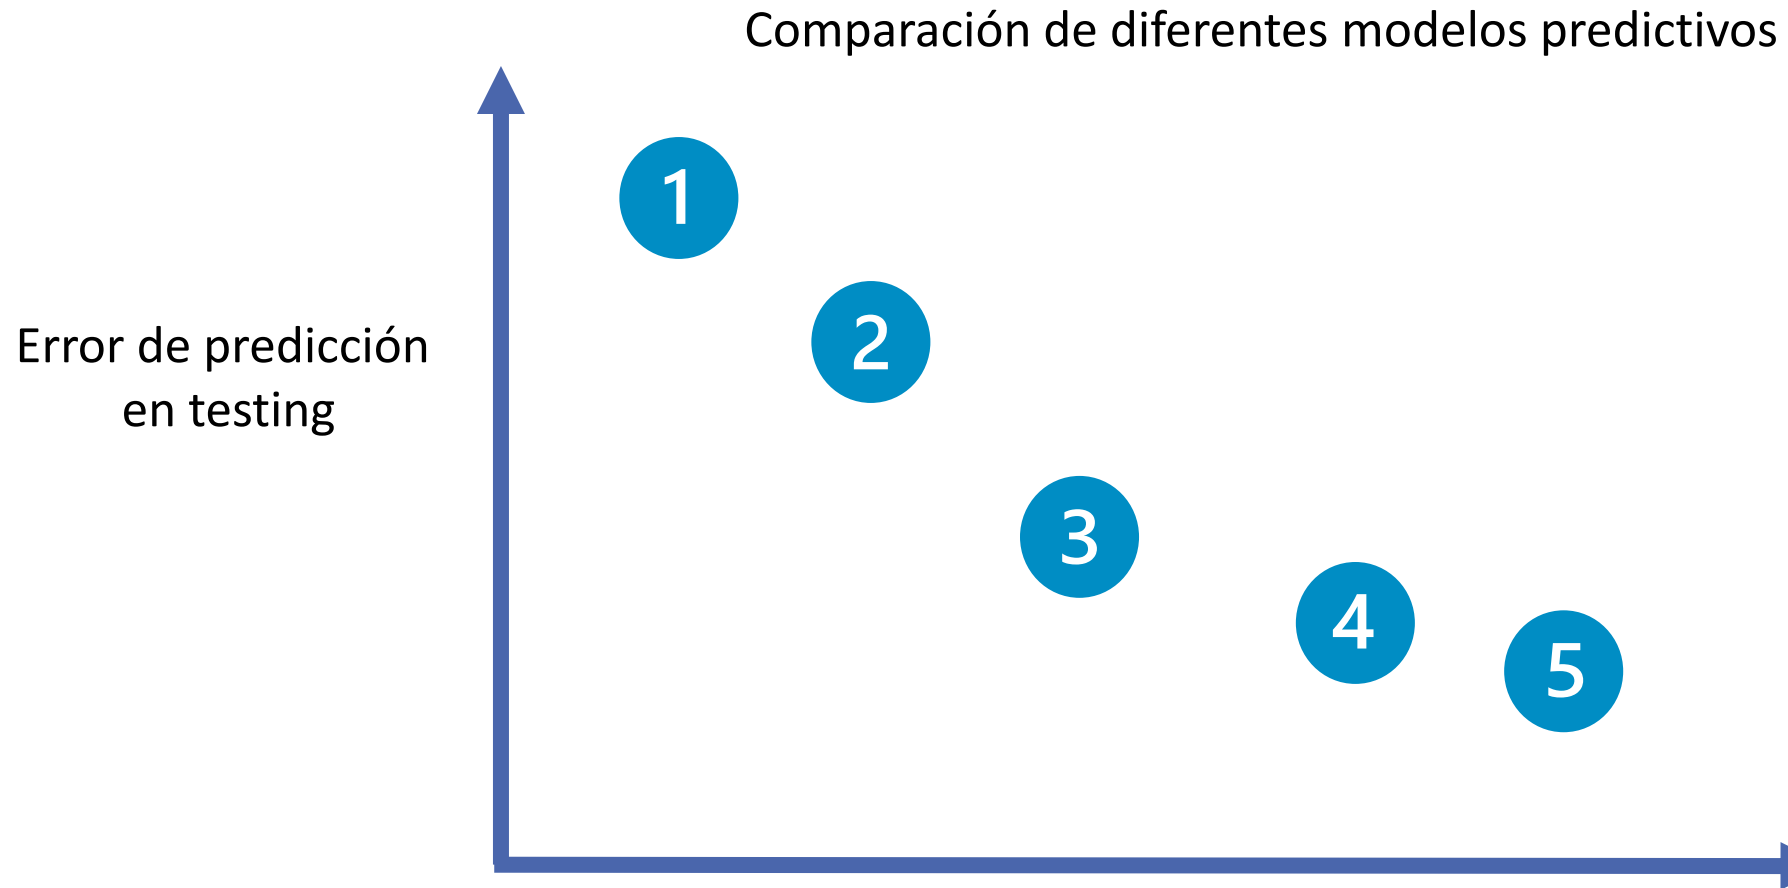
Los algoritmos de machine learning realizan sus predicciones en base a modelos estadísticos que comprueban hipótesis, y por lo tanto también que tienen probabilidad de error.

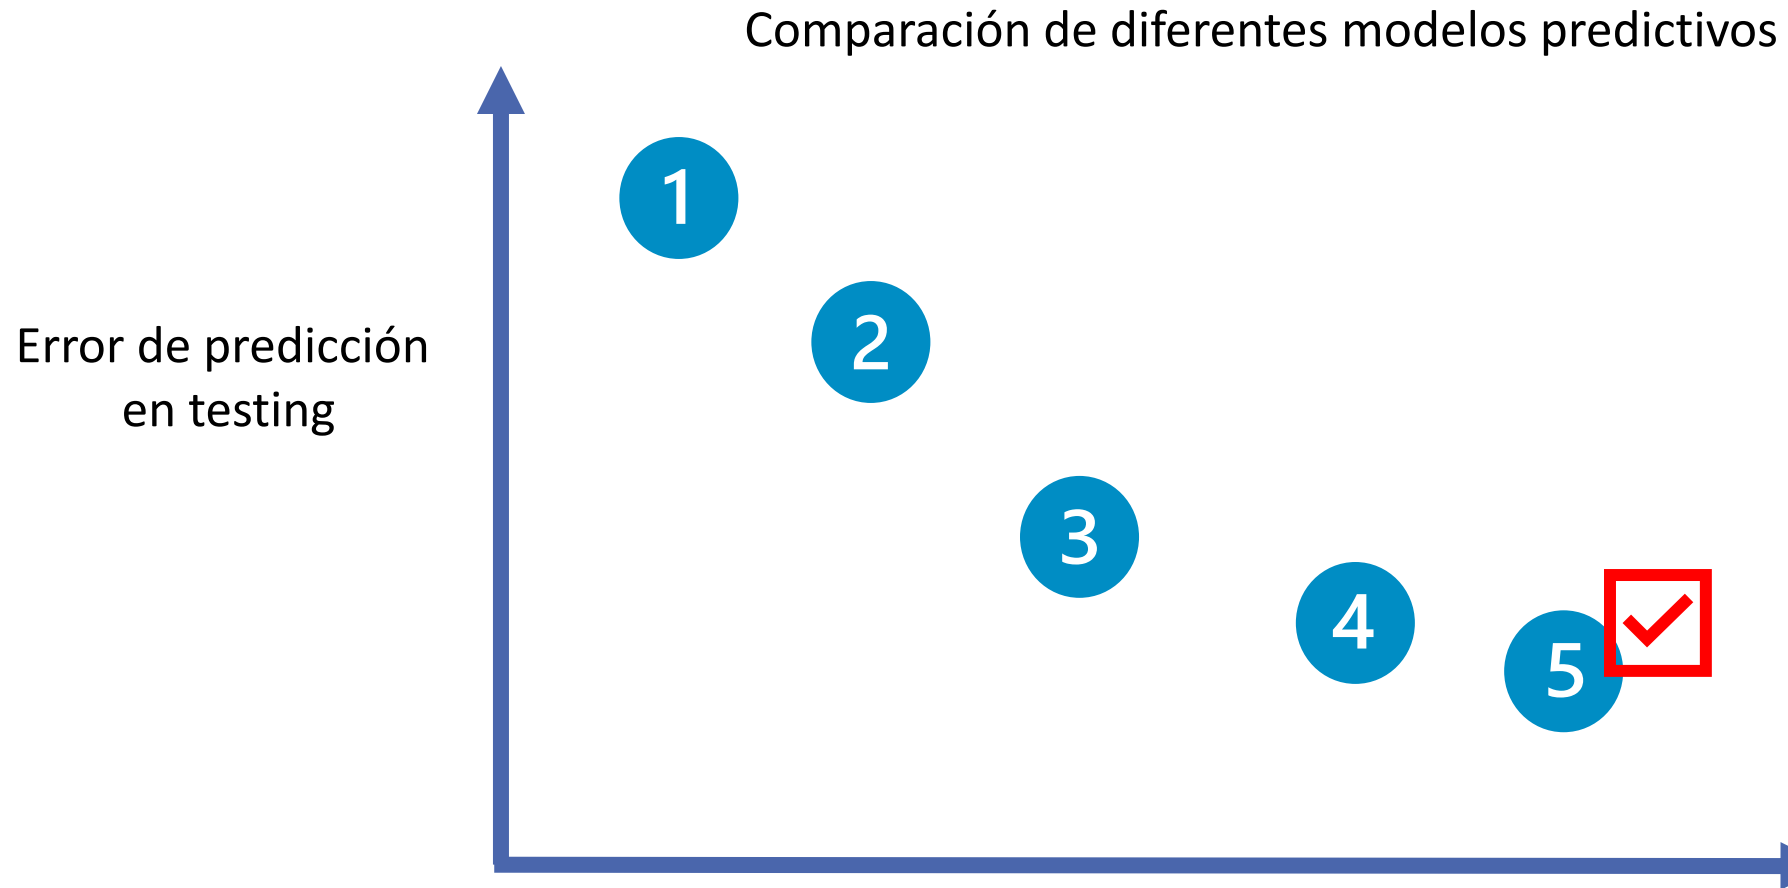
Decisiones Si/No en un proceso de negocio





Vehículos autónomos











Face ID




Security safeguards

Security is important to all of us to protect information on our devices. We have done some important things to safeguard your information, the same way we did with Touch ID. Face ID uses the TrueDepth camera and machine learning for a secure authentication solution. Face ID data - including mathematical representations of your face - is encrypted and protected with a key available only to the Secure Enclave.

The probability that a random person in the population could look at your iPhone or iPad Pro and unlock it using Face ID is approximately 1 in 1,000,000 with a single enrolled appearance. As an additional protection, Face ID allows only five unsuccessful match attempts before a passcode is required. The statistical probability is different for twins and siblings that look like you and among children under the age of 13, because their distinct facial features may not have fully developed. If you're concerned about this, we recommend using a passcode to authenticate.

2007



14 Decision Analysis in Drug Development


By Carl-Fredrik Burman, Andy Grieve, and Stephen Senn

- 14.1 Introduction 385
- 14.2 Introductory Example: Stop or Go? 386
- 14.3 The Structure of a Decision Analysis 392
- 14.4 The Go/No Go Problem Revisited 394
- 14.5 Optimal Sample Size 397
- 14.6 Sequential Designs in Clinical Trials 406
- 14.7 Selection of an Optimal Dose 412
- 14.8 Project Prioritization 421
- 14.9 Summary 426
- Acknowledgments 426
- References 426

Applied Statistical Decision Theory in 1961


Raiffa and Schlaifer (1961)

<https://www.gwern.net/docs/statistics/decision/1961-raiffa-appliedstatisticaldecisiontheory.pdf>




Applied Statistical Decision Theory in 1961
Raiffa and Schlaifer (1961)

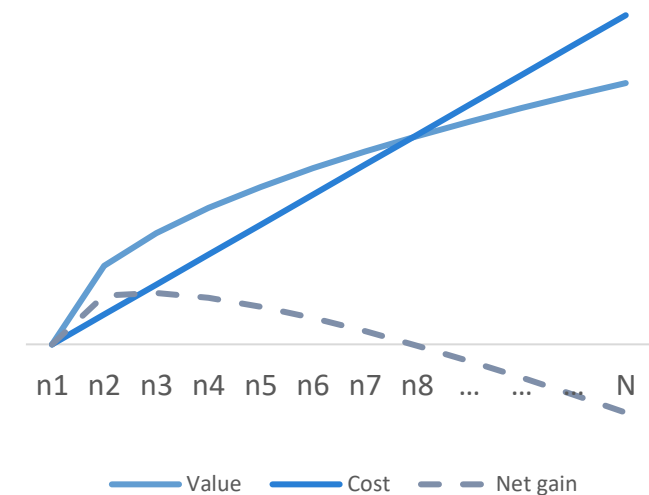
Decision Tree



Terminal Utilities and Opportunity Losses



Optimal Sampling

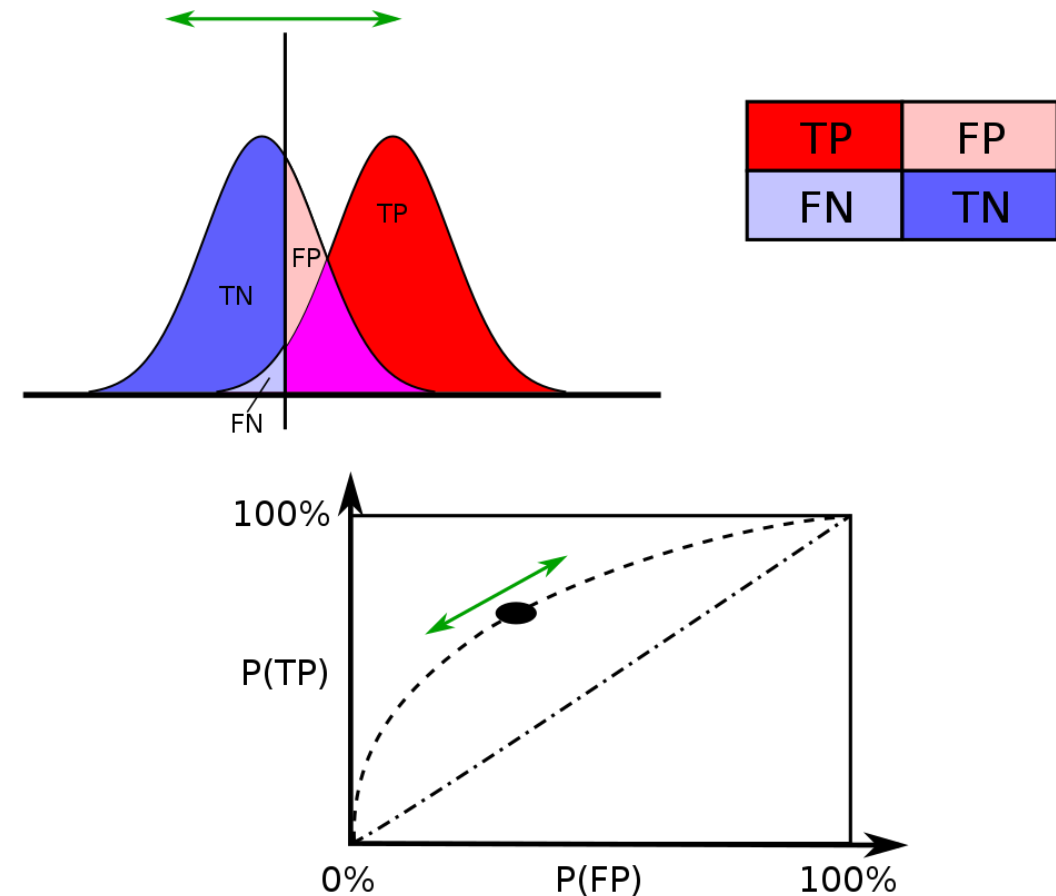


MACHINE LEARNING

MATRIZ DE CONFUSIÓN *

		Realidad	
		No	Si
Predicción	No	Predicción correcta	Error Tipo II (β) Falso negativo
	Si	Error Tipo I (α) Falso-positivo	Predicción correcta

- *En algoritmos de clasificación
Se aplica en la etapa de testing*



MACHINE LEARNING

MATRIZ DE CONFUSIÓN *

Realidad

Predicción	Realidad	
	No	Si
No	Predicción correcta	Error Tipo II (β) Falso negativo
Si	Error Tipo I (α) Falso-positivo	Predicción correcta

- Accuracy
- Precision
- Sensitivity
- Specificity

- *En algoritmos de clasificación*
Se aplica en la etapa de testing

MACHINE LEARNING

MATRIZ DE CONFUSIÓN *

		Realidad	
		No	Si
Predicción	No	Predicción correcta	C2 Error Tipo II (β) Falso negativo
	Si	C1 Error Tipo I (α) Falso-positivo	Predicción correcta

- *En algoritmos de clasificación*
Se aplica en la etapa de testing

- Accuracy
- Precision
- Sensitivity
- Specificity

Cuál es el costo que deseo minimizar?

- C1?: Desperdicio / Costo de oportunidad
- C2?: Trade off

MACHINE LEARNING

MATRIZ DE CONFUSIÓN *

Realidad

Predicción	Realidad	
	No	Si
No	Predicción correcta	C2 Error Tipo II (β) Falso negativo
Si	C1 Error Tipo I (α) Falso-positivo	Predicción correcta

- Accuracy
- Precision
- Sensitivity
- Specificity

- *En algoritmos de clasificación*
Se aplica en la etapa de testing

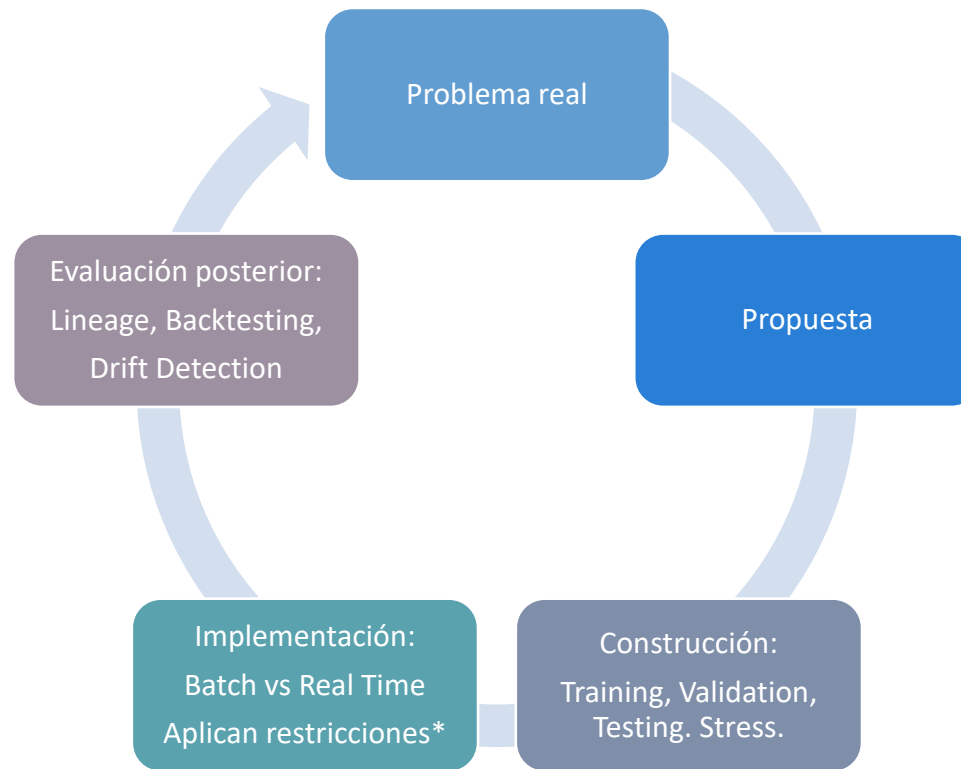
Cuál es el costo que deseo minimizar?

- C1?: Desperdicio / Costo de oportunidad
- C2?: Trade off

Cost-Sensitive Learning

MACHINE LEARNING **LIFECYCLE**

MACHINE LEARNING **LIFECYCLE**




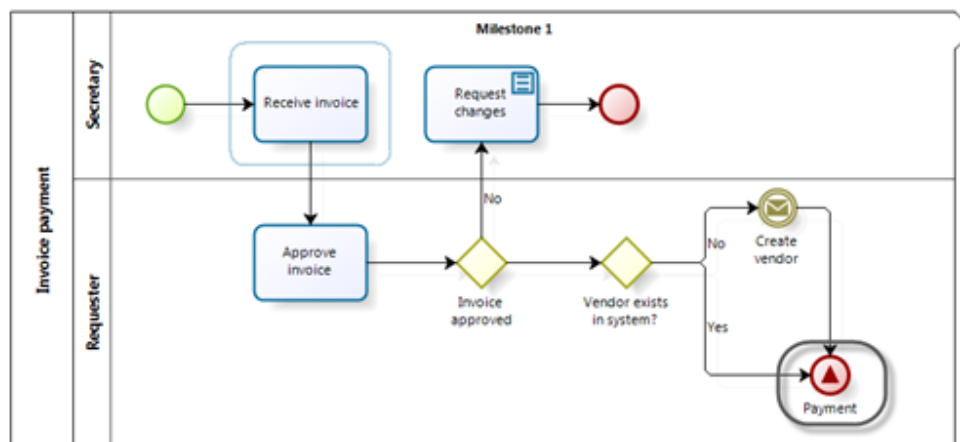
CONSTRUCCIÓN: PRUEBA DE STRESS AL ALGORITMO

Se trata de introducir situaciones extremas y evaluar como reacciona el algoritmo, probando cierta medidas de seguridad y así prevenir el hacking o tricking.

IMPLEMENTACIÓN: RESTRICCIONES PARA QUE SE APLIQUE EL ALGORITMO

El algoritmo no debe ser tomado como un sustituto del proceso en el 100% de los casos.

Recordemos que el modelo fue entrenado bajo ciertas condiciones, por lo que deben considerarse los casos en los que no aplicará!



MACHINE LEARNING **LIFECYCLE**

EVALUACIÓN POSTERIOR

①

Lineage

- Trazabilidad del aprendizaje
- Versionamiento

②

Backtesting

- Comprobar la precisión del modelo en el tiempo.
- Seguimiento a métricas de la matriz de confusión
- Seguimiento al trade off

③

Drift Detection

- Evaluar la variable de respuesta
- Caducidad de ciertas variables del modelo
- El problema cambió.

¿Cuándo es posible delegar decisiones a un algoritmo?

- Suficiencia de datos.
- Nivel de desperdicio, Costo de oportunidad y Trade off aceptado por los stakeholders.
- Considerar que el algoritmo puede o no aplicarse en ciertos casos.
- Niveles de seguridad sean adecuados.
- La evaluación posterior a la implementación esta garantizada.
- Aspectos Legales y éticos.
- Humanos dispuestos a llevar el cambio.



<https://www.raeng.org.uk/publications/responses/algorithms-in-decision-making>

Junio 2020 | Charlas online

¿Cuándo es posible
delegar decisiones a un
algoritmo?

Gracias

Diapositivas en:

Síguenos en:

FB: www.facebook.com/socequest

TW: www.twitter.com/see_estadistica

IG: www.instagram.com/see_estadistica

IN: www.linkedin.com/company/sociedad-ecuatoriana-de-estadistica

Por: Wehrli Pérez Caicer
Sociedad Ecuatoriana de Estadística
wperez@espol.edu.ec

